



Departamentul Automatică și Informatică Industrială

**Facultatea Automatică și Calculatoare
Universitatea Națională de Știință și Tehnologie
POLITEHNICA București**



LUCRARE DE DIPLOMĂ

Recunoașterea multimodală a emoțiilor utilizând rețele neuronale profunde

Coordonator

Dr. ing. Dan Popescu

Absolvent

Rău Flavius Constantin

2026

CUPRINS

1. Introducere.....	3
2. Stadiu actual.....	5
3. Materiale și metode.....	9
4. Rezultate experimentale.....	27
5. Discuții.....	34
6. Concluzii.....	37
7. Bibliografie.....	39

1. Introducere

Emoțiile constituie o componentă esențială a comunicării umane, influențând atât modul în care oamenii transmit informații, cât și modul în care acestea sunt interpretate. Din acest motiv, dezvoltarea unor sisteme capabile să identifice și să interpreteze corect stările emoționale umane a devenit o direcție majoră în cercetarea actuală. Totuși, emoția umană este un fenomen complex și multimodal, exprimat simultan prin modificări ale mimicii faciale, tonului vocii, ritmului vorbirii și dinamicii comportamentale. Limitarea la o singură sursă de informație conduce frecvent la ambiguități și la scăderea performanței sistemelor automate. De exemplu, o expresie facială poate fi ambiguă în lipsa contextului vocal, iar anumite emoții precum frica și tristețea pot avea caracteristici vizuale similare, dar diferențe evidente la nivel acustic.

1.1 Contextul actual

Recunoașterea automată a emoțiilor este o direcție importantă în domeniul inteligenței artificiale afective, având ca obiectiv identificarea stării emoționale a unei persoane pe baza unor semnale observabile, precum expresiile faciale, vocea, limbajul corporal sau conținutul lingvistic. În ultimii ani, interesul pentru această temă a crescut datorită aplicațiilor în interacțiunea om și calculator, sisteme inteligente de asistență, educație digitală, monitorizarea stării psihologice și analiza comportamentală. Spre deosebire de alte sarcini de clasificare, recunoașterea emoțiilor este dificilă deoarece emoțiile nu sunt exprimate întotdeauna clar, iar aceeași stare afectivă poate avea manifestări diferite în funcție de persoană, context, intensitate și modalitatea analizată. Din acest motiv, cercetarea contemporană se orientează tot mai mult către metode multimodale, capabile să combine informația pentru o interpretare mai robustă a stării emoționale [1].

Printre cele mai frecvente modalități se numără analiza vizuală, bazată pe expresii faciale și mișcări ale feței, analiza auditivă, care urmărește tonul, intensitatea și ritmul vocii, precum și analiza textuală, centrată pe conținutul semantic al mesajului. De asemenea, emoțiile pot fi estimate prin observarea mersului și posturii corporale, dar și prin semnale fiziologice, precum activitatea cerebrală, variațiile pulsului, GSR-ul pentru răspunsul galvanic al pielii și ECG-ul pentru activitatea cardiacă. Combinarea acestor modalități permite construirea unor sisteme multimodale mai robuste, capabile să ofere o interpretare mai completă și mai precisă a stării emoționale. Așadar, în urma evoluției academice în cadrul recunoașterii de emoție se remarcă o creștere semnificativă în ultimele 2 decenii. De asemenea, ceea ce privește recunoașterea multimodală a emoțiilor, un fenomen apărut recent, în care în ultimii 5 ani s-a cercetat exponențial, fapt ce arată că domeniul este în plină desfășurare [2].

1.2 Motivarea Cercetării

Lucrarea de față este motivată de necesitatea dezvoltării unui sistem modern de recunoaștere multimodală a emoțiilor care să combine informația vizuală și acustică utilizând arhitecturi Transformer preantrenate pe seturi masive de date. Alegerea bazei de date CREMA-D (Crowd-sourced Emotional Multimodal Actors Dataset) [3] este justificată prin caracterul său multimodal și prin diversitatea actorilor și emoțiilor incluse, oferind un cadru experimental adecvat pentru evaluarea performanței sistemelor de inteligență artificială în recunoașterea emoțiilor din voce și expresii faciale.

În contextul evoluției tehnologice, cercetarea este motivată și de ascensiunea recentă a tehnologiilor hardware și software care permit antrenarea unor modele de mari dimensiuni, precum ViViT [4] și HuBERT [5], utilizând acceleratoare grafice moderne și biblioteci specializate de deep learning. Astfel, implementarea unui sistem multimodal performant devine accesibilă inclusiv în mediul academic, oferind posibilitatea explorării unor soluții avansate pentru analiza afectivă automată. Acest lucru poate reprezenta o bază care să dezvolte în jurul domeniilor ce implică starea sănătății emoționale, aspect reprezentativ în medicină și psihologie.

1.3 Obiectivul Lucrării

Obiectivul principal al acestei lucrări îl reprezintă proiectarea, implementarea și evaluarea unui sistem multimodal de recunoaștere automată a emoțiilor utilizând arhitecturi Transformer pentru analiza simultană a informației video și audio. Sistemul propus urmărește identificarea automată a șase stări emoționale fundamentale, precum furie (angry), dezgust (disgust), frică (fearful), fericire (happy), neutralitate (neutral) și tristețe (sad), pe baza clipurilor multimodale din punct de vedere video și audio din baza de date CREMA-D.

Lucrarea își propune să demonstreze că integrarea informației audio și video conduce la performanțe superioare comparativ cu utilizarea individuală a fiecărei modalități. În plus, cercetarea urmărește evidențierea capacității arhitecturilor Transformer [6] de a modela relațiile temporale complexe dintre cadrele video și secvențele audio, aspect esențial pentru interpretarea corectă a expresiilor emoționale dinamice. Așadar, acest sistem să poată funcționa în aproximativ orice alt mediu extern, având deja o performanță ridicată din mediul în care a fost realizat.

2. Stadiu Actual

2.1 Evoluția metodelor pentru recunoașterea emoțiilor

La începutul studiului de recunoaștere a emoției a fost focalizată strict pe detecția din imagine, astfel au fost folosite rețele neuronale convoluționale de mici dimensiuni dar eficiente pentru un asemenea task individual. De exemplu, arhitectura VGG/VGGNet a fost utilizată frecvent în recunoașterea expresiilor faciale datorită structurii sale simple, bazate pe straturi convoluționale succesive cu filtre mici, care permit extragerea progresivă a caracteristicilor vizuale din imagine. Modelul folosește o arhitectură de tip VGGNet pentru clasificarea emoțiilor pe baza de date FER2013 și arată că, prin reglarea atentă a hiperparametrilor, modelul poate obține performanțe ridicate fără date suplimentare de antrenare. Această abordare demonstrează că VGG rămâne relevant pentru FER, mai ales ca model de bază pentru extragerea trăsăturilor spațiale ale feței. [7]

Un alt model reprezentativ pentru detecția emoției din imagine este ResNet a fost adoptat pe scară largă în recunoașterea emoțiilor faciale datorită conexiunilor reziduale, care permit antrenarea unor rețele mai adânci fără degradarea performanței. Într-un studiu recent despre ResNet-18 pentru facial emotion recognition, autorii arată că această arhitectură oferă un echilibru bun între acuratețe și eficiență computațională pe setul FER2013. Prin conexiunile reziduale, modelul poate extrage caracteristici faciale mai complexe, păstrând stabilitatea antrenării chiar și în rețele profunde [8]. De asemenea și DenseNet se diferențiază prin conexiunile dense dintre straturi, fiecare strat primind ca intrare caracteristicile generate de straturile anterioare. Această reutilizare a trăsăturilor este utilă în recunoașterea expresiilor faciale, unde detaliile fine ale mimicii pot avea un rol important în separarea emoțiilor apropiate. Autorii propun o metodă de recunoaștere a expresiilor faciale multi-view care combină un model DenseNet pentru FER cu normalizare de postură bazată pe GAN, abordând problema variațiilor de unghi și perspectivă ale feței [9].

În evoluția modelării temporale a expresiilor faciale în secvențele video, primele abordări au utilizat frecvent arhitecturi hibride de tip CNN–RNN [10] sau CNN–LSTM [11]. În aceste modele, componenta CNN are rolul de a extrage caracteristici spațiale relevante din fiecare cadru al feței, precum forma ochilor, poziția gurii sau modificările musculare, iar componenta recurentă RNN sau LSTM analizează evoluția acestor caracteristici de-a lungul timpului. Astfel, rețeaua poate surprinde tranzițiile dintre expresii și dinamica emoției pe parcursul unei secvențe video. Cu toate acestea, deși metodele recurente au reprezentat un pas important față de analiza imaginilor statice, ele prezintă limitări în captarea dependențelor temporale pe termen lung și pot deveni dificil de antrenat atunci când secvențele sunt lungi [12].

Apariția arhitecturilor Transformer a schimbat această direcție de cercetare, deoarece mecanismul de self-attention permite pentru fiecare element dintr-o secvență să interacționeze în mod direct cu toate celelalte elemente, fără a depinde de procesarea secvențială specifică rețelelor recurente. Modelul Transformer este bazat exclusiv pe mecanisme de atenție și eliminând nevoia de recurență sau convoluții în procesarea secvențelor [6].

2.2 Recunoașterea emoțiilor din expresii faciale prin secvențe video

Recunoașterea a expresiilor faciale a devenit un domeniu reprezentativ pentru modele de tip Transformer, datorită complexității acestora în a putea procesa cât mai în detaliu caracteristicile fine dintr-o secvență video prin capacitatea de procesare a multor imagini față de o simplă rețea neuronală. Astfel, [13] propune arhitectura Multi-Geometry Embedded Transformer pentru recunoașterea expresiilor faciale în secvențe video. Modelul integrează informații geometrice faciale atât în spațiul euclidian, cât și în spațiul hiperbolic, pentru a surprinde mai bine modificările subtile ale expresiilor și relațiile dintre regiunile feței. Prin combinarea acestor reprezentări geometrice cu mecanismele Transformer, arhitectura poate analiza interacțiunile dintre cadre și dintre zonele faciale relevante, fiind mai eficientă în situații complexe, precum variații de poziție, expresii fine sau ocluzii parțiale. Astfel, această lucrare evidențiază direcția actuală a cercetării către modele Transformer capabile să integreze informație spațială, temporală și geometrică într-un cadru unificat pentru recunoașterea expresiilor faciale dinamice.

Cercetările recente din recunoașterea expresiilor faciale dinamice se concentrează tot mai mult pe modele capabile să combine informația spațială a feței cu evoluția temporală a expresiei în cadrul secvențelor video. Modele precum STAR-Former propun arhitecturi Transformer spatio-temporale care acordă atenție regiunilor faciale relevante și reduc influența cadrelor irelevante, a ocluziilor sau a pozițiilor non-frontale. În aceeași direcție, metodele bazate pe atenție asupra landmark-urilor faciale și pe gruparea temporală a cadrelor urmăresc captarea dependențelor pe termen lung dintre expresiile succesive. Alte lucrări recente evidențiază importanța selecției cadrelor-cheie și a tratării mostrelor zgomotoase sau ambigue, aspecte esențiale pentru recunoașterea robustă a emoțiilor în videoclipuri reale [14].

2.3 Recunoașterea emoțiilor din semnalul vocal

Învățarea automată a semnalelor audio a apărut ca o paradigmă puternică în procesarea vorbirii datorită caracteristicilor subtile a acusticii. Modele precum Wav2vec 2.0, [15] HuBERT [16] și altele [17] sunt pre-antrenate pe volume mari de date vocale neetichetate pentru a învăța reprezentări de uz general. Aceste reprezentări s-au dovedit eficiente atunci când sunt transferate către sarcini ulterioare cum ar fi recunoașterea automată a vorbirii, identificarea vorbitorului și recunoașterea emoțiilor, adesea cu reglaje fine specifice sarcinii minime. Ideea centrală este că, prin învățarea prezicerii unor părți ale semnalului de intrare sau a reprezentărilor sale cuantizate, aceste modele surprind proprietăți acustice și fonetice specifice vorbirii.

2.4 Strategii de fuziune multimodală

Fuziunea multimodală reprezintă etapa prin care informațiile provenite din mai multe surse, precum semnalul audio și secvențele video, sunt integrate pentru a obține o predicție emoțională mai robustă decât în cazul utilizării unei singure modalități. În recunoașterea emoțiilor, cele două fluxuri sunt complementare: componenta vizuală surprinde expresiile faciale, mișcările și dinamica mimicii, în timp ce componenta audio oferă informații despre ton, intensitate, ritm și variații prozodice ale vorbirii. Studiile recente arată că sistemele multimodale pot depăși limitările modelelor unimodale, deoarece o emoție ambiguă într-o modalitate poate fi clarificată prin cealaltă. Totuși, fuziunea datelor eterogene ridică provocări importante, precum alinierea temporală dintre audio și video, diferențelor de dimensionalitate între reprezentări și influența zgomotului sau a lipsei unei modalități. Din acest motiv, literatura actuală discută mai multe strategii de fuziune, precum early fusion, late fusion și hybrid fusion și metode bazate pe atenție sau cross-attention [18].

Un tip important de fuziune este early fusion, în care caracteristicile extrase din fiecare modalitate sunt combinate înainte de etapa de clasificare. În cazul recunoașterii emoțiilor audio-video, acest lucru poate presupune concatenarea vectorilor de caracteristici audio, cum ar fi reprezentările vocale sau descriptorii acustici, cu vectorii extrași din cadrele video sau din expresiile faciale. Avantajul principal al acestei abordări este faptul că modelul poate învăța relații comune între modalități încă de la nivelul reprezentărilor, ceea ce poate duce la o captare mai bună a corelațiilor dintre voce și expresia facială. Totuși, early fusion are și limitări: necesită sincronizare bună între modalități, poate fi sensibilă la diferențele de dimensiune dintre caracteristici și poate deveni dificil de antrenat atunci când una dintre modalități este zgomotoasă sau incompletă [19].

O metoda eficientă este reprezentată printr-un sistem de recunoaștere multimodală a emoțiilor în timp real, în care fiecare modalitate este procesată printr-un model separat, iar combinarea se realizează la nivel decizional, prin late fusion. Lucrarea folosește modele independente pentru text, audio și imagine/video, iar rezultatele sunt combinate pe setul CMU-MOSEI prin metode de tip ensemble, precum bagging și stacking. Un aspect important al studiului este faptul că autorii subliniază avantajul antrenării separate a modelelor unimodale, deoarece fiecare ramură poate exploata particularitățile proprii modalități, iar fuziunea târzie îmbunătățește robustețea predicției finale. Spre deosebire de aceasta lucrare, unde fuziunea se realizează pe mai multe modalități, sistemul propus utilizează o formă mai simplă și mai interpretabilă de fuziune târzie, bazată pe media ponderată a probabilităților finale [20].

O abordare multimodală mai complexă este propusă prin arhitectura AVT-CA (Audio-Video Transformer Fusion with Cross Attention). Spre deosebire de o fuziune ponderată simplă a probabilităților audio și video, această metodă integrează cele două modalități la nivel intermediar, utilizând blocuri Transformer și mecanisme de cross-attention pentru a identifica relațiile relevante dintre informația vocală și expresiile faciale. Modelul aplică suplimentar atenție spațială și pe canale în ramura video, pentru evidențierea regiunilor faciale cu valoare emoțională ridicată. Această strategie permite reducerea problemelor de nesincronizare audio-video și extragerea unor reprezentări mai discriminative. Pe setul CREMA-D, modelul a obținut o acuratețe de 94,13% și un scor F1 de 94,67%, demonstrând avantajul unei fuziuni multimodale în interiorul rețelei față de metoda mai simplă prin fuziune la finalul arhitecturii [21].

3. Materiale și Metode

3.1. Baza de date

Pentru realizarea acestui studiu, am utilizat setul de date **CREMA-D** (Crowd-sourced Emotional Multimodal Actors Dataset), o resursă fundamentală în domeniul recunoașterii automate a emoțiilor datorită naturii sale multimodale și diversității actorilor implicați. Această bază de date a fost dezvoltată printr-un efort de colaborare între mai multe instituții academice pentru a oferi un standard de stimuli emoționali necesari studiilor de neuroimagistică și computaționale [3].

Înregistrările au fost efectuate într-un mediu controlat fonic, utilizând echipamente profesionale (camera Panasonic AG-HPX170). Rezoluția video standard este de 480x360 pixeli (aspect 4:3), iar semnalul audio este eșantionat la 16 kHz. Aceste caracteristici tehnice fac din CREMA-D un set de date ideal pentru integrarea tehnicilor moderne de procesare.

Un aspect distinctiv față de alte baze de date al CREMA-D este sistemul de adnotare prin crowdsourcing: 2.443 de evaluatori unici au adnotat clipurile în trei condiții : audio-video complet, doar video și doar audio , astfel fiecare clip primind în medie 9,84 adnotări. Eticheta finală este determinată prin votul majoritar, ceea ce conferă o robustețe superioară față de adnotările realizate de un singur expert. Așadar, cu 7.441 de clipuri originale, există un total de 22.326 de elemente de adnotat. Obiectivul a fost colectarea în medie a cam 10 evaluări pentru fiecare element, pentru un total de 223.260 de evaluări individuale. Evaluatorii au vârste între 18 și 89 de ani , vârsta medie fiind de 43 ani, unde 40,5% erau de sex masculin și 59,5% de sex feminin [3].

CREMA-D este un set de date multimodal care conține 7,441 de clipuri originale de la 91 de actori, dintre care 48 de bărbați și 43 de femei, cu vârste cuprinse între 20 și 74 de ani, provenind din diverse origini etnice (afro-americani, asiatici, caucazieni, hispanici și nespecificați). Astfel, în cadrul proiectului regizat, media de vârstă a actorilor este de 36 de ani, iar distribuția acestora poate fi vizualizată în **Tabelul 1**.

Grupă de vârstă	Număr actori
20-29 ani	34
30-39 ani	23
40-49 ani	16
50-59 ani	12
60-69 ani	5
Peste 70 ani	1

Tabelul 1. Distribuția pe vârste a actorilor din baza de date CREMA-D.

Actorii au rostit 12 propoziții diferite în șase stări emoționale: furie (angry), dezgust (disgust), frică (fearful), fericire (happy), neutralitate (neutral) și tristețe (sad). Setul de date este disponibil public și a fost utilizat atât pentru extragerea caracteristicilor audio din formatul WAV pentru antrenarea modelului audio, cât și pentru antrenarea modelului de recunoaștere facială a emoțiilor (imagini statice extrase din clipuri video .flv) . Sunt afișate tipurile de emoții din modulul video în imagini pentru câte un actor în parte în figura următoare **Figura 1**:




Figura 1: Frame-uri cu tipurile de emoții din baza de date CREMA-D

Fișierele audio ce caracterizează intrarea semnalului vocal este reprezentat în **Figura 2**, unde din formele de undă se pot observa distincții acustice între clasele emoționale. De exemplu, semnalele de fericire și furie prezintă fluctuații de amplitudine pronunțate și oscilații frecvente, indicând o intensitate vocală ridicată. De asemenea, emoția de frică este caracterizată prin vârfuri bruște de intensitate și o structură asimetrică, reflectând instabilitatea și ritmul alert al vorbirii. Contrar, starea neutră și cea de tristețe demonstrează o variație considerabil mai redusă a amplitudinii de-a lungul axei timpului, sugerând un ton mai liniar, un ritm încetinit și o energie vocală minimă, în timp ce dezgustul prezintă oscilații minore, fiind o emoție exprimată adesea mai pronunțat la nivel facial decât acustic.




Figura 2: Formele de undă specifice celor 6 clase

Fiecare actor a rostit 12 propoziții prestabilite în limba engleză, concepute să fie neutre din punct de vedere semantic, cu șase emoții la patru niveluri de intensitate: scăzut (Low), mediu (Medium), ridicat (High) și nespecificat (XX). Propozițiile sunt construite astfel încât emoția să fie transmisă exclusiv prin intonație și expresie, nu prin conținutul lexical. Acestea pot fi vizualizate în **Tabelul 2** [3].

Nr.	Propoziție
1.	Este ora unsprezece.
2.	Exact asta s-a întâmplat
3	Sunt în drum spre întâlnire
4.	Mă întreb despre ce este vorba
5.	Avionul este aproape plin
6.	Poate mâine va fi frig
7.	Aș dori un ceas deșteptător nou
8.	Cred că am o programare la medic
9.	Nu uita o jachetă
10.	Cred că am mai văzut asta înainte
11.	Suprafața este alunecoasă
12.	Ne vom opri în câteva minute

Tabelul 2: Propozițiile utilizate în înregistrările CREMA-D, toate cu conținut semantic neutru

Fiecare videoclip din baza de date CREMA-D este identificat printr-un cod unic structurat în patru componente de forma ActorID_Propoziție_Emoție_Intensitate. Prima componentă este identificatorul numeric al actorului (de exemplu, 1001, 1002 etc.). A doua componentă este abrevierea propoziției rostite, derivată din inițialele cuvintelor cheie: IEO (It's Eleven O'clock), TIE (That Is Exactly what happened), IOM (I'm On My way to the meeting), IWW (I Wonder What this is about), TAI (The Airplane Is almost full), MTI (Maybe Tomorrow It will be cold), IWL (I Would Like a new alarm clock), ITH (I Think I Have a doctor's appointment), DFA (Don't Forget A jacket), ITS (I Think I've Seen this before), TSI (The Surface Is slick) și WSI (We'll Stop In a couple of minutes). A treia componentă indică emoția exprimată: ANG (furie), DIS (dezgust), FEA (frică), HAP (fericire), NEU (neutru) și SAD (tristețe). A patra componentă specifică nivelul de intensitate al exprimării: LO (scăzut), MD (mediu), HI (ridicat), sau XX în cazul în care intensitatea nu a fost prestabilită. Astfel, un fișier denumit 1001_IEO_HAP_HI corespunde clipului în care actorul cu ID-ul 1001 rostește propoziția „It's eleven o'clock” exprimând fericire la intensitate ridicată, în timp ce un fișier precum 1042_DFA_ANG_XX reprezintă actorul 1042 rostind „Don't forget a jacket” cu o expresie de furie la o intensitate nespecificată [3].

3.2 Preprocesarea Datelor

3.2.1 Preprocesarea datelor Video

Împărțirea datelor în seturi de antrenare, validare și testare urmează o strategie within-actor stratificată. Spre deosebire de strategia actor-level (care separă complet actorii între seturi), strategia within-actor permite fiecărui actor să contribuie cu clipuri în toate cele trei seturi, menținând proporțiile claselor emoționale per actor. Întregul pipeline de preprocesare a fost proiectat astfel încât să trateze separat cele două modalități video și audio, înainte de a fi combinate în etapa de fuziune. Setul de date a fost împărțit în trei partiții: antrenare (5.543 clipuri), validare (1.177 clipuri) și testare (720 clipuri), menținând distribuția echilibrată a claselor în fiecare partiție, rezumată în **Tabelul 3**.

Set	Nr. clipuri	Proporție
Antrenare	5.543	75,6%
Validare	1.177	14,8%
Test	720	9.8%
Total	7.441	100%

Tabelul 3: Rezultatul împărțirii within-actor (6 clase)

O provocare specifică clipurilor din CREMA-D este că actorii sunt filmați în plan semi-larg, incluzând atât fața, cât și o parte a bustului, pe un fundal de culoare verde. Aplicarea directă a unui crop central de 224×224 pixeli ar introduce în mod sistematic zone de fundal sau zone ale bustului care nu conțin informație emoțională relevantă, degradând calitatea semnalului vizual transmis rețelei. Pentru a rezolva această problemă, a fost implementat un mecanism de detectare automată a feței bazat pe clasificatorul Haar Cascade, disponibil în biblioteca OpenCV. Algoritmul Haar Cascade, propus inițial de Viola [22], în care utilizează un set de caracteristici bazate pe diferențe de intensitate luminoasă în regiuni rectangulare ale imaginii (caracteristici Haar), evaluate rapid printr-un mecanism de imagine integrală. Clasificarea se face printr-o cascadă de clasificatori slabi (AdaBoost), care elimină rapid regiunile fără față și concentrează procesarea pe

zonele candidate. Astfel, mai jos este prezentat frameul original în comparație cu cel preprocesat în **Figura 3**:




Figura 3: Preprocesare frame prin tehnica haarcascade [22]

După aplicarea crop-ului și redimensionarea la 224×224 pixeli (acolo unde este necesar), fiecare cadru este convertit din reprezentarea uint8 [0, 255] la float32 [0.0, 1.0] prin împărțire la 255. Ulterior, se aplică normalizarea per-canal cu media și deviația standard calculate pe setul ImageNet, valori standard utilizate și pentru preantrenarea modelului ViViT pe Kinetics-400 (1):

$$\text{pixel_normalizare} = (\text{pixel} - \text{Media}) / \text{Deviația_standard} \quad (1)$$

unde Media = [0.485, 0.456, 0.406] și Deviația_standard = [0.229, 0.224, 0.225] sunt valorile standard pentru canalele RGB. Această normalizare aliniază distribuția datelor de intrare cu distribuția pe care rețeaua a fost preantrenată, facilitând transferul de cunoștințe și accelerând convergența în etapa de fine-tuning. În final, fiecare clip video este reprezentat ca un tensor de dimensiune [64, 224, 224, 3], corespunzând celor 64 de cadre procesate, fiecare de rezoluție 224×224 pixeli și 3 canale de culoare (RGB). Acest tensor este transmis direct modelului ViViT ca intrare.

Fiecare videoclip din CREMA-D are o durată medie de aproximativ 2,5 secunde și a fost filmat la o frecvență de 30 de cadre pe secundă, rezultând între 60 și 90 de cadre brute per clip. Modelul ViViT (Video Vision Transformer) utilizat în această lucrare operează cu un număr fix de cadre de intrare, impus de arhitectura preantrenată google/vivit-b-16x2-kinetics400 pe baza de date Kinetics400 [23]. Prin urmare, din fiecare clip au fost eșantionate uniform 64 de cadre, garantând acoperirea uniformă a întregii durate a clipului indiferent de lungimea acestuia. Eșantionarea uniformă a fost preferată față de eșantionarea aleatoare pentru a asigura reproductibilitatea rezultatelor și pentru a evita pierderea informației emoționale de la începutul sau sfârșitul clipului, unde expresia emoțională este adesea cel mai pregnant. Este demonstrat în **Figura 4**, cronologia celor 64 de frame-uri în cadrul fiecărui videoclip, în acest caz fiind actorul 1001, ce exprima propoziția „It's Eleven O'clock”, arătând emoția angry(supărare) la un grad de intensitate ridicat(High).




Figura 4: Cele 64 de frame-urile cronologice din compoziția unui videoclip

Prin eșantionarea a 64 de cadre din fiecare dintre cele 7.441 de clipuri ale bazei de date CREMA-D, pipeline-ul de preprocesare video generează un total de 475.424 de imagini individuale (64×7.441), ceea ce echivalează cu aproximativ jumătate de milion de cadre procesate, fiecare normalizat și aliniat spațial prin mecanismul de detectare HaarCascade descris anterior.

3.2.2 Preprocesarea datelor Audio

Semnalul audio este extras din clipurile video originale și adus la o frecvență de eșantionare de 16.000 Hz (16 kHz), aceasta fiind frecvența de eșantionare standard cu care a fost preantrenat modelul audio utilizat HuBERT (Hidden-Unit BERT). Modificarea frecvenței de eșantionare este realizată prin interpolare de înaltă calitate, pentru a minimiza artefactele spectrale introduse în acest proces. Semnalul rezultat este un vector monofonic de valori float32, normalizat în intervalul $[-1.0, 1.0]$. Acest model a fost preprocesat înainte la preantrenare prin clasificatorul K-Means pe caracteristicile coeficienților acustici MFCC (Mel-Frequency Cepstral Coefficients)[16].

3.3 Rețele neuronale utilizate

3.3.1 Modulul video

Recunoașterea emoțiilor din expresii faciale dinamice este o problemă fundamental temporală: o expresie de frică, de exemplu, nu este definită de un singur cadru static, ci de tranziția dintre starea neutră și cea de vârf emoțional, inclusiv micro-expresiile tranzitorii care apar și dispar în fracțiuni de secundă. Abordările clasice bazate pe rețele convoluționale 2D (CNN) aplicate cadru cu cadru și agregate ulterior ignoră tocmai această dimensiune temporală, pierzând informații despre ordinea și viteza de schimbare a expresiei faciale.

Dezvoltate inițial în cadrul domeniului procesării limbajului natural, arhitecturile de tip Transformer, ce se bazează pe mecanismul de atenție, au dovedit o eficiență ridicată în captarea și modelarea dependențelor pe termen lung. Extinderea lor la domeniul video a condus la apariția modelelor Video Vision Transformer (ViViT), care tratează secvența de cadre video ca o secvență de token-uri vizuale și aplică mecanisme de atenție spațio-temporală pentru a captura relații între orice pereche de cadre, indiferent de distanța temporală dintre ele. Aceasta face din ViViT o alegere natural potrivită pentru recunoașterea emoțiilor din video, unde expresia emoțională se desfășoară pe întreaga durată a clipului. Arhitectura modelului Transformer este reprezentată în **Figura 5** [6].




Figura 5: Arhitectura modelului Transformer generală [6]

Modelul original, ilustrat în Figura 4, este compus din două componente principale: un encoder (stânga) și un decoder (dreapta), fiecare repetat de N ori. În contextul recunoașterii emoțiilor din video, arhitectura ViViT utilizează exclusiv stiva de encodare, deoarece sarcina de clasificare nu implică generarea unei secvențe de ieșire, așadar reprezintă producerea unei singure etichete emoționale pe baza întregului clip video. În **Figura 6**, este prezentată structura prin care este dezvoltată recunoașterea emoției.




Figura 6: Arhitectura modelului transformer utilizat

Primul pas în procesarea datelor pentru această arhitectură constă în transformarea intrărilor brute în reprezentări numerice de tip dense. Fiecare segment spațio-temporal extras din clipul video este aplatizat și proiectat liniar într-un vector de dimensiune $D=768$, obținând astfel embedding-ul inițial al token-ului. Deoarece mecanismul de atenție este prin natura sa invariant la permutări, adică tratează secvența ca o mulțime neordonată, fără a distinge pozițiile token-urilor fiind necesară adăugarea explicită a informației de poziție. Aceasta se realizează prin sumarea unui vector de embedding pozițional la fiecare token, vector care codifică atât coordonatele spațiale ale patch-ului în cadru, cât și coordonata sa temporală în secvența de cadre.

Al doilea pas este reprezentat de nucleul fiecărui bloc transformer îl constituie mecanismul de atenție multi-cap (Multi-Head Self-Attention), care permite fiecărui element al secvenței să interacționeze direct cu toți ceilalți, indiferent de distanța dintre ei. Formal, fiecare token este proiectat simultan în trei spații vectoriale distincte prin transformări liniare învățate, producând vectorii de interogare Q (query), cheie K (key) și valoare V (value). Reprezentarea actualizată a fiecărui token este calculată ca sumă ponderată a tuturor vectorilor V din secvență, cu ponderile date de aceste scoruri. Mecanismul este replicat în paralel pe H capete independente, fiecare operând în proiecții diferite ale aceluiași spațiu de reprezentare, permițând modelului să surprindă simultan tipuri variate de relații între token-uri locale și globale, la distanțe arbitrare în secvență.

Apoi, ieșirile celor H capete de atenție sunt concatenate și proiectate liniar înapoi în spațiul de reprezentare de dimensiune D , după care rezultatul este adăugat la intrarea blocului prin intermediul unei conexiuni reziduale, iar suma este normalizată prin Layer Normalization. Aceste conexiuni reziduale sunt esențiale pentru antrenarea rețelelor de mare adâncime: ele permit gradientilor să se propage direct prin model fără a traversa obligatoriu toate transformările intermediare, prevenind problema dispariției gradientilor și asigurând stabilitatea numerică a procesului de optimizare. Fiecare bloc Transformer conține, pe lângă sub-modulul de atenție, și un strat feed-forward (FFN) compus din două transformări liniare cu o activare neliniară între ele, aplicat independent fiecărui token, urmat la rândul său de o conexiune reziduală și normalizare de strat.

Pe parcursul tuturor celor N straturi, token-ul special [CLS] interacționează prin mecanismul de atenție cu toți ceilalți token-uri din secvență, acumulând o reprezentare globală condensată a întregii intrări. La ieșirea ultimului strat, reprezentarea acestui token este transmisă capului de clasificare, compus dintr-un bloc MLP (Multilayer Perceptron) urmat de funcția de activare softmax. Blocul MLP realizează o proiecție neliniară a reprezentării extrase de encoder într-un spațiu de dimensiune redusă, corespunzător numărului de clase țintă: acesta este alcătuit din unul sau mai multe straturi liniare complet conectate, separate de funcții de activare neliniară, care permit modelului să învețe granițe de decizie complexe în spațiul reprezentărilor. Funcția softmax aplicată la ieșirea blocului MLP transformă scorurile brute produse de ultimul strat liniar într-o distribuție de probabilitate normalizată peste clasele țintă, suma tuturor probabilităților fiind egală cu 1, clasa cu probabilitatea maximă constituind predicția finală a modelului. Arhitectura completa a detecției emoției din video este reprezentare în **Figura 7**.




Figura 7. Arhitectura completa a detecției emoției din video

Am folosit modelul preantrenat google/vivit-b-16x2-kinetics400, ce a fost antrenat pe setul de date kinetics 400[25]. Acest set de date gigantic, creat de DeepMind (Google) pentru a antrena modele de inteligență artificială să înțeleagă acțiunile umane în timp. Denumirea acestuia exprima 400 de tipuri de acțiuni umane diferite, de exemplu cum ar fi cântatul la chitara sau o strângere de mana. Acesta conține peste 300.000 de clipuri, unde fiecare clip provine de pe YouTube și are o durată de aproximativ 10 secunde. În **Figura 8**, apar 2 tipuri de acțiuni ce au loc în cadrul setului

kinetics-400 [23]. Alegerea arhitecturii ViViT (Video Vision Transformer), pre-antrenată pe setul de date Kinetics-400, reprezintă o strategie superioară față de o rețea convoluțională ce poate înregistra emoția doar din cadre statice și izolate, astfel această abordare poate defini o dinamică temporală a expresiilor faciale.



Figura 8: Acțiuni din setul de date Kinetics-400 (strângere de mână, respectiv cântat la vioară) [23]

Parametrii arhitecturali și de antrenare ai modelului ViViT utilizat în această lucrare sunt centralizați în **Tabelul 4**. Astfel, configurația arhitecturală reflectă direct alegerile teoretice descrise: dimensiunea de embedding $D=768$, cele 12 capete de atenție și dimensiunea stratului feed-forward de 3.072 corespund specificațiilor modelului de bază ViViT-B preantrenat pe Kinetics-400, în timp ce cele 4 straturi Transformer adăugate, capul de clasificare Linear(768, 6) și funcția softmax de ieșire reprezintă adaptările realizate pentru sarcina de recunoaștere a celor 6 emoții din CREMA-D.

Parametru	Valoare
Model preantrenat	google/vivit-b-16x2-kinetics400
Rezoluție cadru intrare	224×224 pixeli
Dimensiune patch spațial	16×16 pixeli
Nr. token-uri generate per clip	$6.272 + 1$ [CLS]
Dimensiune embedding (D)	768
Nr. capete de atenție	12
Dimensiune strat feed-forward (FFN)	3.072
Nr. clase de ieșire	6
Cap de clasificare	Linear(768, 6)
Nr. total parametri	120.590.854

Tabelul 4: Parametrii pentru modelul utilizat pentru recunoașterea emoțiilor din video

3.3.2 Modulul audio

Recunoașterea emoțiilor din semnal vocal reprezintă o provocare fundamentală în domeniul prelucrării audio, determinată de variabilitatea acustică ridicată dintre vorbitori, de suprapunerea parțială a caracteristicilor spectrale ale diferitelor emoții și de absența unor indicatori acustici universal valabili pentru fiecare stare emoțională. Abordările tradiționale de recunoaștere a emoțiilor din voce se bazau pe extragerea manuală de caracteristici acustice coeficienți MFCC (Mel-Frequency Cepstral Coefficients), frecvența fundamentală (pitch), energia semnalului sau caracteristici de tip spectrograma Mel.

Odată cu apariția modelelor de tip Transformer preantrenate prin auto-supervizare pe cantități masive de date audio, paradigma s-a schimbat fundamental. Aceste modele, dintre care cel mai reprezentativ este Wav2Vec2 și HuBert (Hidden-Unit BERT), sunt capabile să învețe reprezentări acustice bogate direct din forma de undă brută, fără a necesita etichete sau cunoștințe prealabile despre conținutul semnalului. Prin expunerea la sute sau mii de ore de înregistrări audio, modelul dezvoltă intern reprezentări care codifică simultan informație fonetică, prozodică și emoțională, toate relevante pentru sarcina de recunoaștere a emoțiilor.

Un model de baza este reprezentat de Wav2Vec2, ce conține un codificator de caracteristici convoluțional multistrat care procesează forma de undă brută pentru a genera reprezentări latente ale vorbirii la intervale regulate. Convoluțiile din cele șapte blocuri au 512 canale, cu pași (5,2,2,2,2,2,2) și lățimi de kernel (10,3,3,3,3,2,2), rezultând o frecvență de ieșire de 49 Hz, un pas de aproximativ 20ms între eșantioane și un câmp receptiv de 400 de eșantioane de intrare, adică 25ms de audio. Lățimile de kernel (10,3,3,3,3,2,2) definesc câte eșantioane audio sunt analizate simultan de fiecare strat convoluțional, astfel primul strat identifică 10 eșantioane deodată pentru a captura structuri mai largi, iar straturile ulterioare reduc progresiv această fereastră, așa că pașii (5,2,2,2,2,2,2) determină cu câte eșantioane se deplasează fereastra la fiecare pas, pasul total multiplicativ de 320 de eșantioane ($5 \times 2 \times 2 \times 2 \times 2 \times 2 \times 2$) fiind cel care produce frecvența de ieșire de aproximativ 49 Hz la o rată de eșantionare de 16 kHz. Al doilea bloc este un encoder transformer care procesează această secvență și produce reprezentările contextualizate, în care fiecare cadru înglobează informație despre întreaga secvență audio prin mecanismul de atenție multi-head. Arhitectura modelului transformer Wav2vec2 este în **Figura 9** [24].




Figura 9: Arhitectura model transformer Wav2Vec2 [24]

În timp ce wav2vec 2.0 folosește o pierdere contrastivă, HuBERT (Hidden-Unit BERT) utilizează o abordare de clusterizare. Modelul învață să prezică grupuri de unități (cluster-e de sunete) cu un clasificator K-Means folosit pe caracteristicile acustice coeficienți MFCC (Mel-Frequency Cepstral Coefficients), ceea ce îl face extrem de eficient în captarea nuanțelor fonetice și a variațiilor de ton subtile, vitale pentru detectarea emoțiilor. Alegerea HuBERT ca model pentru modalitatea audio în această lucrare este motivată tocmai de această capacitate de reprezentare generală, combinată cu posibilitatea de adaptare eficientă prin fine-tuning pe setul de date CREMA-D.

HuBERT este un model de reprezentare a vorbirii bazat pe învățare auto-supervizată prin predicție mascată [16]. Arhitectura sa similară cu cea a Wav2Vec2 este compusă din două componente principale dispuse secvențial: un encoder convoluțional (CNN Encoder) care procesează forma de undă brută și produce o secvență de reprezentări acustice de joasă dimensiune, și un encoder Transformer de tip BERT care procesează această secvență și produce reprezentări contextuale bogate pentru fiecare segment temporal.. HuBERT primește la intrare direct forma de undă brută (raw waveform), eliminând orice pas de extragere manuală a caracteristicilor și permițând modelului să descopere automat reprezentările optime pentru sarcina dată.

Modelul Hubert utilizat este preantrenat pe setul de date WenetSpeech L, care cuprinde 10.000 de ore de vorbire în limba chineză. Datele provin în principal de pe YouTube și Podcast și acoperă diverse scenarii de înregistrare, zgomote de fundal și stiluri de vorbire, incluzând domenii precum cărți audio, documentare, știri, interviuri, discursuri și altele. Acesta a folosit la preantrenare comparativ cu Wav2Vec2, un clasificator K-Means ce are rolul pentru ca să se ignore zgomotul de fundal mai eficient, concentrându-se pe componentele semantice și prozodice ale

vorbirii, ceea ce îmbunătățește precizia în medii acustice diverse. Arhitectura modelului Hubert este reprezentată în **Figura 10**.




Figura 10: Arhitectura modelului HuBert utilizat [16]

Arhitectura completa de recunoaștere a emoției din modalitatea audio este reprezentată în **Figura 11**, prin mai multe etape succesive. Punctul de plecare îl constituie preantrenarea modelului HuBERT pe corpusul WenetSpeech L de 10.000 de ore de vorbire, în cadrul căreia algoritmul k-means aplicat pe caracteristicile MFCC generează etichetele de cluster necesare obiectivului de predicție mascată [25]. După care se utilizează pe CREMA-D, unde forma de undă brută a fiecărui clip audio este mai întâi cuantizată, producând o secvență de token-uri discrete la care se adaugă doi token-uri speciali: [MASK] pentru pozițiile mascate în preantrenare și [CLS] pentru agregarea globală a informației. Fiecare token este proiectat printr-un strat de Token Embedding într-un vector de dimensiune $D=768$, obținând secvența de intrare pentru encoder-ul Transformer. Aceasta este procesată de blocul Transformer, compus din straturi de Multi-Head Attention urmate de normalizare (Norm), conexiuni reziduale (+) și straturi feed-forward, producând reprezentări contextualizate bogate pentru fiecare poziție temporală. Reprezentarea token-ului [CLS] la ieșirea ultimului strat Transformer, prin care condensează informația emoțională a întregii enunțări, unde este transmisă capului de clasificare compus dintr-un bloc

MLP, apoi funcția softmax aplicată la ieșire produce o distribuție de probabilitate peste cele șase clase emoționale: Angry, Happy, Sad, Neutral, Disgust și Fearful, clasa cu probabilitatea maximă constituind predicția finală a modelului [5].




Figura 11: Arhitectura completa a detecției emoției prin modalitatea audio

3.3.3 Fuziunea modulelor Video si Audio

Sistemul aplică o fuziune bazată pe ponderi pentru a îmbina cele două reprezentări ale modalităților. În această metodă, se antrenează împreună două ponderi scalare care pot fi învățate, una destinată incorporării audio și cealaltă pentru cea video. În etapa de antrenament, modelul identifică valorile optime pentru aceste ponderi, având în vedere cât de relevantă este fiecare modalitate în procesul de clasificare a emoțiilor. Reprezentările audio și video, după aplicarea ponderilor, sunt apoi combinate, rezultând o singură reprezentare, prezentată în **Figura 12**. Acest mecanism de ponderare permite modelului să evalueze autonom ce tip de informații ar trebui să influențeze mai mult predicția finală.

Fuziunea cu ponderi, utilizată în cadrul proiectului are o caracteristică ce implică o adaptabilitate excelentă. Aceasta implică alegerea a cărei modalități să poată influența mai mult sau mai puțin rezultatul final. Astfel, în funcție de performanța unui model în cadrul unei modalități, care ar fi mai performantă decât altul, se poate alege un coeficient între 0 și 1 care reprezintă cât de mult poate influența rezultatul final. Așadar, modalitatea video sau audio care este mai performantă tinde să fie reprezentată de un coeficient cel puțin egal cu 0.5. De exemplu, dacă modalitatea video are o performanță 80% și audio de 85%, atunci putem înmulți toate probabilitățile din video 0.35, iar cele din audio cu 0.65, apoi să fie însumate egal cu 1.




Figura 12: Arhitectura fuziunii finale prin ponderi a celor 2 modalități (video din **Figura 7** și audio din **Figura 11**)

3.4 Resurse utilizate

Dezvoltarea unui sistem multimodal de recunoaștere a emoțiilor bazat pe arhitecturi Transformer de mari dimensiuni impune cerințe semnificative atât în ceea ce privește infrastructura hardware, cât și ecosistemul software utilizat. Acest capitol descrie în detaliu resursele computaționale și bibliotecile utilizate pe parcursul implementării, antrenării modelelor și evaluării sistemului propus, punând în evidență provocările tehnice întâmpinate și soluțiile adoptate.

3.4.1 Infrastructura Hardware

Antrenarea modelelor de deep learning la scara utilizată în această lucrare necesită acceleratoare hardware specializate cu memorie mare și capacitate de calcul paralel ridicată. Accesul la resurse computaționale adecvate a fost asigurat prin infrastructura Grid a Universității Politehnice din București, conectată prin nodul de acces fep.grid.pub.ro. Alocarea resurselor GPU s-a realizat prin sistemul de gestiune a cozilor SLURM, utilizând partiția dgxh100.

Nodul de calcul principal utilizat a fost dgxh100-precis-wn01, echipat cu GPU NVIDIA H100 80GB HBM3 — una dintre cele mai performante acceleratoare disponibile comercial la momentul realizării lucrării. Antrenarea modelului ViViT a necesitat alocarea a 64 GB memorie RAM de sistem și a unui singur GPU, configurație care a permis executarea tuturor experimentelor în condiții de stabilitate.

Pe lângă serverul de calcul al universității, a fost configurată și o stație de lucru locală pentru testarea sistemului de utilizare în condiții realiste, fără acces la GPU dedicate. Utilizarea pe

CPU necesită aproximativ 60-90 secunde per clip video de 2-3 secunde, timp dominat de pasul de forward propagation prin modelul ViViT (120M parametri). Această durată este acceptabilă pentru demonstrarea funcționalității sistemului.

3.4.2 Mediul Software

Întregul proiect a fost implementat în Python 3.12, utilizând un mediu virtual izolat. Izolarea mediului virtual garantează reproductibilitatea experimentelor și evitarea conflictelor între versiunile diferitelor biblioteci. Python 3.12 a fost ales pentru compatibilitatea sa completă cu versiunile recente ale bibliotecilor PyTorch și HuggingFace Transformers. În **Tabelul 5**, se regăsesc toate bibliotecile principale utilizate în cadrul proiectului.

Bibliotecă	Versiune	Utilizare în proiect
PyTorch	2.x + CUDA 12.x	Framework principal deep learning — definirea modelelor, antrenarea, inferența, managementul GPU
HuggingFace Transformers	4.x	Încărcarea modelelor preantrenate ViViT și HuBERT, fine-tuning, salvare în format safetensors
HuggingFace Datasets	2.x	Utilitar pentru gestionarea și accesarea modelelor din HuggingFace Hub
OpenCV (cv2)	4.x	Citirea fișierelor video .flv, conversia cadrelor, detecția facială Haar Cascade, preprocesarea video
librosa	0.10.x	Încărcarea fișierelor .wav, extragerea MFCC, analiza semnalelor audio
soundfile	0.12.x	Citirea fișierelor .wav pe Windows (alternativă la librosa pe Windows cp1252)
NumPy	1.26.x	Operații pe array-uri, preprocesarea datelor, calcule statistice
pandas	2.x	Gestionarea CSV-urilor de split (train.csv, val.csv, test.csv), filtrarea și iterarea datelor

scikit-learn	1.4.x	StratifiedShuffleSplit pentru împărțirea datelor, metrici de evaluare (accuracy, F1, confusion matrix)
matplotlib	3.8.x	Generarea graficelor de antrenare, vizualizări waveform, spectrograme, matrici de confuzie
seaborn	0.13.x	Vizualizări estetice ale matricilor de confuzie cu heatmap
tqdm	4.x	Bare de progres pentru iterații lungi de antrenare și evaluare
ffmpeg	6.x	Extragerea pistei audio din fișierele video .flv pentru inferența locală

Tabelul 5: Bibliotecile principale utilizate în proiect

3.4.3 Gestionarea modelelor preantrenate

Modelele preantrenate utilizate în lucrare au fost descărcate automat din HuggingFace Hub la prima apelare în și stocate local în cache-ul implicit (~/.cache/huggingface/). Modelele descărcate și utilizate sunt:

google/vivit-b-16x2-kinetics400 — modelul ViViT preantrenat pe Kinetics-400, fișiere de configurare și ponderi, utilizat ca punct de pornire pentru fine-tuning-ul video.

TencentGameMate/chinese-hubert-base — modelul HuBERT preantrenat pe date de voce chinezești, ~378 MB, utilizat la fel ca punct de pornire pentru finetuning-ul pentru recunoașterea emoțiilor din voce.

Modelele fine-tuned au fost salvate în format HuggingFace safetensors (model.safetensors) pentru compatibilitate maximă, și în format PyTorch checkpoint (.pt) pentru modulul video, incluzând metadata despre epoca de antrenare și acuratețea pe setul de validare.

4. Rezultatele experimentale

În acest capitol sunt prezentate rezultatele experimentale obținute pentru cele trei configurații evaluate: modelul audio HuBERT fine-tuned pe CREMA-D, modelul video ViViT și a sistemul multimodal obținut prin fuziune ponderată. Analiza procesului de antrenare a modelelor de recunoaștere a emoțiilor s-a realizat prin analiza funcției de pierdere (loss) și a metricii de acuratețe, monitorizate pe parcursul tuturor epocilor de antrenare, atât pe setul de antrenare, cât și pe cel de validare.

Valorile funcției de pierdere(loss) prezentate în graficele de antrenare și validare au fost utilizate pentru monitorizarea convergenței modelului și pentru identificarea eventualelor fenomene de supraînvățare(overfitting). O scădere progresivă a pierderii indică îmbunătățirea capacității modelului de a clasifica corect emoțiile din datele analizate. Funcția penalizează predicțiile incorecte și acordă valori mai mici ale pierderii atunci când modelul atribuie o probabilitate ridicată clasei corecte. În expresia matematică, C semnifică numărul de clase, y_i reprezintă eticheta reală a clasei i , iar $\hat{y}_i$ reprezintă probabilitatea estimată de model pentru aceeași clasă.

$$L = - \sum_{i=1}^C y_i \log(\hat{y}_i) \quad (2)$$

În **Figura 13**, modelul video a fost antrenat timp de 29 de epoci, utilizând mecanismul de early stopping cu o răbdare (patience) de 8 epoci. Antrenarea s-a structurat în două faze distincte: o fază de warm-up (epocile 1–5), în care straturile preantrenate ale arhitecturii ViViT au fost înghețate, urmate de o fază de fine-tuning (epocile 6–29), în care întreaga rețea a fost antrenată cu o rată de învățare redusă. Saltul de pierdere vizibil în jurul epocii 6 pe setul de antrenare este caracteristic tranziției de la warm-up la fine-tuning: deblocarea straturilor înghețate și resetarea parțială a optimizatorului determină o recalibrare temporară a gradientilor, urmată rapid de o convergență stabilă și susținută. Cel mai bun model s-a obținut la epoca 21, moment în care pierderea de validare a atins un minim local.




Figura 13: Evoluția funcției de pierdere pentru modelul video ViViT (Train Loss vs. Validation Loss)

În **Figura 14**, se ilustrează evoluția acurateței pe seturile de antrenare și validare. Acuratețea de antrenare a crescut progresiv de la 32.1% la 93.5%, reflectând capacitatea ridicată a modelului de a învăța reprezentările din datele de antrenare. Acuratețea de validare a atins valoarea maximă de **83.52%** la epoca 21.




Figura 14: Evoluția acurateții (Train Accuracy vs. Validation Accuracy)

Figura 15 prezintă curbele de pierdere pentru modelul audio. Pierderea pe setul de antrenare înregistrează o scădere monotonă și regulată, de la 1.590 la 0.487, fără discontinuități sau salturi bruște, ceea ce atestă stabilitatea procesului de fine-tuning. Pierderea de validare scade rapid în primele 4 epoci, după care oscilează în intervalul $[0.54 - 0.69]$, atingând minimul global la epoca 11 (valoare: 0.549).




Figura 15: Evoluția funcției de pierdere pentru modelul audio HuBERT (Train Loss vs. Validation Loss)

Figura 16 reprezintă evoluția acurateții de validare pentru modelul audio. Curba urcă rapid în primele epoci, stabilizându-se în intervalul 75–81% începând cu epoca 4. Valoarea maximă de 80.68% pe setul de validare a fost obținută la epoca 11, așadar aceasta reprezintă o performanță destul de rapidă.




Figura 16: Evoluția acurateții pentru modelul audio HuBERT (Acuratețea la antrenare și la validare)

Evaluarea finală a fost realizată pe un set de test echilibrat, format din 720 de exemple, cu 120 de exemple pentru fiecare dintre cele șase clase emoționale: Angry, Disgust, Fearful, Happy, Neutral și Sad. Această distribuție uniformă permite compararea directă a performanțelor pe clase și elimină influența dezechilibrului de date în interpretarea rezultatelor.

Rezultatele modelelor testate sunt interpretate sub forma metricilor de performanță, unde aceștia se bazează pe indicii reprezentativi, TP -True Positive (Adevărat Pozitiv), TN - True Negative (Adevărat Negativ), FP - False Positive (Fals Pozitiv), FN - False Negative (Fals Negativ).

Metric performantă	Formulă	Metric performantă	Formulă
Acuratețe =	$\frac{TP + TN}{TP + FP + TN + FN}$	Sensibilitate =	$\frac{TP}{TP + FN}$
Precizie =	$\frac{TP}{TP + FP}$	Scorul F1 =	$\frac{2TP}{2TP + FP + FN}$

4.1 Performanțele modelului audio Hubert

Modelul audio bazat pe HuBERT a obținut o acuratețe globală de 84,17%, clasificând corect 606 exemple din totalul de 720. Rezultatul confirmă faptul că semnalul vocal conține informații relevante pentru recunoașterea emoțiilor, în special prin variațiile de ton, intensitate, ritm și expresivitate vocală. Cele mai bune rezultate au fost obținute pentru clasa Angry, cu 116 exemple corecte din 120, adică o sensibilitate de 96,7%. De asemenea, clasa Neutral a fost recunoscută foarte bine, cu 111 exemple corecte și 92,5% sensibilitate. Clasele mai dificile pentru modelul audio au fost Fearful, cu 90 exemple corecte, și Sad, cu 87 exemple corecte. Cea mai importantă confuzie apare între Fearful și Sad, unde 20 de exemple reale Fearful au fost prezise ca Sad. În plus, clasa Sad este confundată de 15 ori cu Disgust, de 8 ori cu Fearful și de 9 ori cu Neutral, ceea ce indică suprapuneri acustice între aceste emoții. În **Tabelul 6**, precum și în **Figura 17** se observă raportul complet al modelului Hubert.

Clasă	Precizie	Sensibilitate	F1-score	Suport	Corect	Greșit
Angry	95,6%	96,67%	91,34%	120	116	4
Disgust	82,91%	80,83%	81,86%	120	97	23
Fearful	83,83%	75,00%	78,95%	120	90	30
Happy	90,05%	87,50%	90,52%	120	105	15
Neutral	82,34%	92,50%	87,40%	120	111	9
Sad	71,5%	72,50%	74,04%	120	87	33
Media/ Total	84,33%	84,17%	84,02%	720	606	114

Tabelul 6: Raportul de clasificare a emoțiilor pe modelul audio HuBERT




Figura 17: Matricea de confuzie pentru modelul audio HuBERT fine-tuned pe CREMA-D

4.2 Performantele modelului video ViViT(Video Vision Transformer)

Modelul video bazat pe ViViT și preprocesare Haar Cascade a obținut o acuratețe globală de 82,50%, cu 594 de exemple corect clasificate din 720. Rezultatele arată că informația vizuală este importantă pentru emoțiile cu expresii faciale evidente, însă performanța este afectată în cazul emoțiilor cu manifestări vizuale apropiate sau cu intensitate redusă.

Cea mai bună performanță a modelului video este obținută pentru clasa Happy, unde sunt clasificate corect 117 exemple din 120, adică 97,5% sensibilitate. Clasa Disgust este de asemenea recunoscută bine, cu 107 exemple corecte și 89,2% sensibilitate. În schimb, clasele Fearful și Neutral au câte 90 de exemple corecte, corespunzând unei sensibilități de 75,0%. O confuzie importantă apare între Neutral și Sad, unde 22 de exemple Neutral sunt prezise ca Sad. De asemenea, 20 de exemple Fearful sunt clasificate ca Sad, ceea ce sugerează că expresiile faciale ale fricii și tristeții pot fi dificil de separat vizual. Raportul complet este reprezentat de **Tabelul 7**, precum și în matricea de confuzie din **Figura 18**.

Clasă	Precizie	Sensibilitate	F1-score	Suport	Corect	Greșit
Angry	79,2%	79,17%	83,70%	120	95	25
Disgust	88,7%	89,17%	92,24%	120	107	13
Fearful	75,0%	75,00%	78,60%	120	90	30
Happy	96,55%	97,50%	93,60%	120	117	3
Neutral	75,0%	75,00%	78,95%	120	90	30
Sad	78,2%	79,17%	69,34%	120	95	25
Media / Total	82,11%	82,50%	82,74%	720	594	126

Tabelul 7: Raportul de clasificare pentru modelul video ViViT




Figura 18: Matricea de confuzie pentru modelul video ViViT

4.3 Performanța sistemului multimodal prin fuziune

Sistemul multimodal, obținut prin fuziune ponderată între ViViT și HuBERT, a obținut cea mai bună performanță dintre toate configurațiile evaluate. Fuziunea a fost realizată cu pondere de 35% pentru modelul video și 65% pentru modelul audio. Această configurație a obținut o acuratețe globală de 89,86%, clasificând corect 647 exemple din 720.

Comparativ cu modelul audio, fuziunea aduce o creștere de 5,69 puncte procentuale, iar comparativ cu modelul video aduce o creștere de 7,36 puncte procentuale. Cele mai bune rezultate sunt obținute pentru Angry, cu 117 exemple corecte și 97,5% sensibilitate, Happy, cu 114 exemple corecte și 95,0% recall, și Neutral, cu 113 exemple corecte și 94,2% sensibilitate. Clasa Sad crește semnificativ față de modelele unimodale, ajungând la 102 exemple corecte și 85,0% sensibilitate.

Clasa Fearful rămâne cea mai dificilă, cu 94 de exemple corecte și 78,3% sensibilitate, iar numărul confuziilor Fearful Sad scade de la 20 la 15. Raportul complet este reprezentat în **Tabelul 8**, precum și în matricea de confuzie din **Figura 19**.

Clasă	Precizie	Sensibilitate	F1-score	Suport	Corect	Greșit
Angry	96.3%	97,50%	92,86%	120	117	3
Disgust	88,5%	89,17%	89,54%	120	107	13
Fearful	76.00%	78,33%	85,07%	120	94	26
Happy	94,0%	95,00%	95,80%	120	114	6
Neutral	94,20%	94,17%	92,24%	120	113	7
Sad	84,4%	85,00%	83,27%	120	102	18
Media / Total	88,99%	89,86%	89,80%	720	647	73

Tabelul 8: Raportul de clasificare pentru fuziunea modulelor video și audio cu proporțiile alese empiric 35% pentru modelul ViViT și 65% pentru modelul HuBERT




Figura 19: Matricea de confuzie a fuziunii modelelor ViViT 35% + HuBERT 65%

5. Discuții

5.1 Interpretarea rezultatelor obținute

Rezultatele experimentale confirmă ipoteza principală a lucrării, conform căreia integrarea informației audio și video conduce la o recunoaștere mai robustă a emoțiilor decât utilizarea unei singure modalități. Pe setul de test echilibrat, format din 720 de exemple, modelul video ViViT + Haar Cascade a obținut 82,50%, modelul audio HuBERT a obținut 84,17%, iar sistemul multimodal prin fuziune târzie ponderată a obținut 89,86%. Creșterea performanței după fuziune arată că cele două fluxuri nu sunt redundante, ci complementare: fiecare corectează o parte dintre erorile produse de celălalt.

Diferența dintre modelul audio și modelul video poate fi explicată prin specificul bazei de date CREMA-D. Actorii rostesc propoziții neutre semantic, iar emoția este transmisă prin expresie facială, ton, intensitate și ritm al vorbirii. Lucrarea originală CREMA-D arată că datele au fost evaluate în condiții audio-only, visual-only și audio-visual, ceea ce confirmă importanța analizării separate și combinate a modalităților. În experimentele realizate, componenta audio a avut un avantaj ușor, probabil datorită caracteristicilor prozodice puternice din voce.

Totuși, componenta video rămâne esențială. Emoții precum fericirea și dezgustul sunt adesea exprimate prin indicatori vizuali clari, precum zâmbetul, poziția sprâncenelor sau mișcările gurii. În schimb, clase precum frica, tristețea și neutralitatea pot avea expresii faciale apropiate, ceea ce explică o parte dintre confuziile modelului video. Prin combinarea cu semnalul audio, sistemul multimodal poate reduce aceste ambiguități și poate produce o decizie mai stabilă.

5.2 Discuție asupra componentei video

Pentru analiza video a fost utilizat modelul ViViT, deoarece recunoașterea emoțiilor din clipuri nu se reduce la clasificarea unui singur cadru. O expresie emoțională se dezvoltă în timp, prin tranziții ale mimicii faciale. ViViT transformă videoclipul într-o secvență de token-uri spațio-temporale și le procesează prin straturi Transformer, permițând modelarea relațiilor dintre cadre diferite [26]. Această proprietate este potrivită pentru CREMA-D, unde emoția este exprimată pe durata întregului clip.

În comparație cu arhitecturi CNN precum VGG, ResNet, DenseNet, MobileNet sau EfficientNet, ViViT are avantajul modelării directe a temporalității. CNN-urile pot extrage foarte bine trăsături spațiale dintr-o imagine facială, dar pentru video au nevoie de agregare suplimentară sau de module recurente. În lucrarea de față, alegerea ViViT a fost justificată de obiectivul de a analiza dinamica expresiei, nu doar un cadru static. Totuși, ViViT are un cost computațional mai ridicat, iar performanța sa depinde de calitatea detecției feței și a decupării cadrelor. Preprocesarea cu Haar Cascade a avut rolul de a concentra informația pe regiunea facială și de a reduce influența fundalului. Această alegere este importantă deoarece în cadrele CREMA-D apar și zone care nu contribuie direct la recunoașterea emoției. Limitarea este că Haar Cascade rămâne o metodă clasică și poate fi mai puțin robustă decât detectoarele moderne în situații cu ocluzii sau poziții nefrontale. În condițiile controlate ale bazei CREMA-D, metoda este însă suficientă pentru extragerea regiunii feței.

5.3 Discuție asupra componentei audio

Componenta audio a fost bazată pe HuBERT, un model de învățare auto-supervizată care învață reprezentări ale vorbirii prin predicția unor unități ascunse obținute prin clusterizare. Spre deosebire de metodele clasice bazate pe MFCC, pitch sau energie, HuBERT extrage reprezentări direct din semnalul vocal, fără a depinde exclusiv de caracteristici proiectate manual [16]. Acest lucru este util pentru recunoașterea emoțiilor, deoarece emoția vocală se manifestă prin informații subtile de ritm, intensitate, ton și prozodie.

Performanța de 84,17% obținută de modelul audio arată că vocea conține indicii afective foarte puternice în CREMA-D. Deoarece propozițiile sunt neutre semantic, modelul nu se bazează pe cuvinte emoționale, ci pe modul în care acestea sunt rostite. Acest aspect favorizează un model precum HuBERT, capabil să surprindă informație acustică și prozodică. Cele mai mari dificultăți apar între emoții vocale apropiate, precum frica și tristețea, unde tonul și ritmul pot avea trăsături similare.

Alegerea HuBERT este justificată și de direcția actuală a cercetării către modele preantrenate și self-supervised learning. Aceste modele pornesc de la reprezentări generale ale vorbirii și pot fi adaptate prin fine-tuning la sarcini specifice, inclusiv recunoașterea emoțiilor. Dezavantajul constă în necesarul mai mare de resurse, dar în cazul lucrării de față performanța obținută justifică utilizarea unui model audio modern.

5.4 Discuție asupra fuziunii multimodale

Fuziunea multimodală reprezintă elementul central al sistemului propus. În loc să se ia o decizie pe baza unei singure surse, sistemul combină predicțiile modelului audio și ale modelului video. Strategia aleasă este fuziunea târzie ponderată, în care fiecare model este antrenat separat, iar probabilitățile finale sunt combinate prin ponderi. Această abordare oferă modularitate, deoarece fiecare componentă poate fi analizată și înlocuită independent.

Ponderea de 65% pentru HuBERT și 35% pentru ViViT reflectă performanța individuală mai bună a modelului audio. Alegerea este justificată experimental: dacă o modalitate are o acuratețe mai mare, este logic ca decizia finală să îi acorde o influență mai mare. În același timp, păstrarea contribuției video este importantă, deoarece anumite emoții sunt mai bine exprimate vizual. Rezultatul final, 89,86%, confirmă faptul că ponderarea celor două fluxuri a fost benefică.

Comparativ cu early fusion, late fusion este mai simplă și mai ușor de controlat. Early fusion ar necesita combinarea reprezentărilor audio și video înainte de clasificare, ceea ce presupune aliniere temporală și compatibilitate dimensională. Comparativ cu cross-attention, metoda aleasă este mai puțin complexă, dar și mai interpretabilă. Pentru o lucrare de licență, această alegere este potrivită deoarece demonstrează clar beneficiul multimodalității fără a introduce o arhitectură excesiv de dificilă.

5.5 Comparație cu metode alternative

Pentru componenta video, alternativele principale ar fi fost CNN-uri clasice, precum VGG, ResNet sau DenseNet. Acestea sunt potrivite pentru clasificarea imaginilor statice și pot fi mai eficiente computațional, dar nu modelează direct dinamica expresiei în timp la fel ca o arhitectură transformer. Pentru componenta audio, o alternativă ar fi fost extragerea manuală de caracteristici precum MFCC și clasificarea cu o rețea mai simplă. HuBERT a fost preferat deoarece oferă reprezentări audio mai bogate și transferabile. Pentru fuziune, o alternativă ar fi fost early fusion sau cross-attention. Early fusion poate învăța corelații între modalități la nivel de caracteristici, dar necesită aliniere atentă. Cross-attention poate captura relații mai complexe între voce și imagine,

dar este mai costisitor și mai greu de antrenat. În schimb, late fusion ponderat oferă o soluție echilibrată între performanță, simplitate și interpretabilitate. În **Tabelul 9**, sunt reprezentate aceste tipuri de soluții.

Rețea utilizată	Număr clase	Acuratețe	Descrierea soluției propuse
VGGNet [7]	7	73.28% (FER2013-imagini)	Clasificarea expresiilor faciale utilizând straturi convoluționale succesive și filtre de dimensiuni reduse.
ResNet-18 [8]	7	74.10% (FER2013-imagini)	Utilizarea conexiunilor reziduale pentru extragerea caracteristicilor faciale complexe.
DenseNet [9]	7	77.30% (FER2013-imagini)	Reutilizarea caracteristicilor între straturi
CNN + RNN [10]	7	80.20%(EWD2020-Imagini + semnale fiziologice)	Modelarea evoluției temporale a expresiilor faciale în videoclipuri.
Multi-Geometry Transformer [13]	7	69.91%(DFEW-Video)	Integrarea informațiilor geometrice faciale și a mecanismelor de atenție.
STAR-Former [14]	7	70,00% (DFEW-Video)	Atenție spațio-temporală pentru expresii faciale dinamice.
AVT-CA [21]	6	94.13% (CREMA D -Video + Audio)	Această soluție necesită un grad ridicat de complexitate, fuziunea realizându-se în interiorul rețelei.
ViViT-HuBERT + fuziune ponderată	6	89.86% (CREMA D- video + audio)	Integrarea informațiilor audio și video prin combinarea ponderată a probabilităților finale.
TAV-RF [20]	6	85,85% (CMU-MOSEI Text + Audio + Video)	Fuziunea a predicțiilor indepedente din text, audio și video, combinate printr-un clasificator de tip Random Forest.

Tabelul 9: Tabel cu rezultate si soluții comparative

5.6 Limitări ale sistemului propus

O primă limitare este legată de baza de date. CREMA-D conține emoții exprimate de actori în condiții controlate, nu emoții complet spontane din interacțiuni reale. Astfel, deși rezultatele sunt bune pe acest set, performanța în scenarii reale ar putea fi mai scăzută. Emoțiile naturale pot fi subtile, amestecate sau mascate, iar expresia lor depinde de context și de particularitățile persoanei.

O a doua limitare este folosirea unui set de șase clase discrete. În realitate, emoțiile nu sunt întotdeauna separate clar, iar o persoană poate exprima simultan mai multe stări afective. O altă

limitare este faptul că late fusion nu permite interacțiuni profunde între reprezentările interne audio și video. În viitor, această problemă ar putea fi tratată prin fuziune intermediară sau cross-attention.

În ansamblu, sistemul are un cost computațional relativ ridicat. ViViT și HuBERT sunt modele puternice, dar necesită resurse hardware mai mari decât arhitecturile CNN ușoare. Pentru aplicații în timp real ar fi necesare optimizări precum reducerea numărului de cadre, cuantizarea sau distilarea modelelor.

6. Concluzii

Lucrarea a prezentat proiectarea, implementarea și evaluarea unui sistem multimodal pentru recunoașterea emoțiilor din date audio-video. Sistemul utilizează ViViT pentru analiza secvențelor video și HuBERT pentru analiza semnalului vocal, iar predicțiile celor două modele sunt combinate prin fuziune târzie ponderată. Scopul principal a fost demonstrarea faptului că integrarea audio-video poate îmbunătăți performanța față de abordările unimodale.

Alegerea ViViT a permis analizarea emoției ca proces temporal, nu doar ca imagine statică. Alegerea HuBERT a permis folosirea unor reprezentări audio moderne, obținute prin auto-supervizare. Fuziunea târzie ponderată a oferit un mecanism simplu și interpretabil de combinare a celor două modele, păstrând modularitatea sistemului.

În ansamblu, lucrarea demonstrează că un sistem bazat pe modele preantrenate și fuziune multimodală poate obține performanțe ridicate pe CREMA-D. Rezultatele validează alegerea arhitecturilor utilizate și confirmă importanța analizării simultane a vocii și expresiei faciale în recunoașterea emoțiilor.

6.1 Contribuțiile lucrării

Prima contribuție este realizarea unui pipeline complet, care include preprocesarea video, preprocesarea audio, antrenarea modelelor unimodale, evaluarea acestora și fuziunea finală. A doua contribuție este utilizarea ViViT pentru recunoașterea emoțiilor din secvențe video, ceea ce permite captarea relațiilor temporale dintre cadre. A treia contribuție este integrarea HuBERT pentru analiza emoției vocale, modelul audio având cea mai bună performanță unimodală. A patra contribuție este aplicarea unei fuziuni târzii ponderate, cu 35% pentru video și 65% pentru audio, care a dus la cea mai bună acuratețe globală.

6.2 Direcții viitoare

O direcție viitoare constă în extinderea sistemului cu o a treia modalitate, precum textul. Aceasta ar fi utilă pe seturi de date conversaționale, unde conținutul semantic al mesajului contribuie la identificarea emoției. O altă direcție este integrarea semnalelor fiziologice, precum EEG, ECG sau GSR, care pot reflecta stări interne dificil de observat prin voce sau expresie facială.

O altă direcție importantă este înlocuirea fuziunii târzii cu o metodă mai avansată, precum intermediate fusion sau cross-attention. Aceste metode ar permite interacțiunea directă între

reprezentările audio și video și ar putea reduce confuziile dintre clase apropiate, precum frica și tristețea. În același timp, ar crește complexitatea modelului, fiind necesare resurse mai mari de antrenare.

De asemenea, se poate realiza o baza de date într-un mediu cât mai natural pentru testarea sistemului cu emoții spontane, pentru a evalua capacitatea de generalizare în condiții reale. CREMA-D este un set controlat, iar aplicațiile reale implică zgomot, expresii subtile și variații mari între persoane. De asemenea, sistemul ar putea fi optimizat pentru inferență în timp real prin distilare, cuantizare sau reducerea numărului de cadre video procesate.

7.Bibliografie

- [1] Poria, Soujanya & Hazarika, Devamanyu & Majumder, Navonil & Mihalcea, Rada. (2020). Beneath the Tip of the Iceberg: Current Challenges and New Directions in Sentiment Analysis Research. 10.48550/arXiv.2005.00357.
- [2] Yazici, Adnan & Kucukyilmaz, Tayfun & Dökeroğlu, Tansel & Sharipbay, Aidana & Lee, Min-Ho & Tyler, Benjamin. (2026). State-of-the-art Multimodal Emotion Recognition: A comprehensive survey and taxonomy. Intelligent Systems with Applications. 30. 200642. 10.1016/j.iswa.2026.200642.
- [3] Cao H, Cooper DG, Keutmann MK, Gur RC, Nenkova A, Verma R. CREMA-D: Crowdsourced Emotional Multimodal Actors Dataset. IEEE Trans Affect Comput. 2014 Oct-Dec;5(4):377-390
- [4] I. G. Zahia, L. Ichim and D. Popescu, "A Multimodal System for Emotion Recognition," 2026 IEEE 23rd Mediterranean Electrotechnical Conference (MELECON), Cairo, Egypt, 2026, pp. 1-6
- [5] Chakhtouna A, Sekkate S, Adib AProcedia Computer Science (2024) Unveiling embedded features in Wav2vec2 and HuBERT models for Speech Emotion Recognition,232 2560-2569
- [6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In Advances in Neural Information Processing Systems, pages 5998–6008
- [7] Khairuddin, Yousif & Chen, Zhuofa. (2021). Facial Emotion Recognition: State of the Art Performance on FER2013. 10.48550/arXiv.2105.03588.
- [8] Kumari, FACIAL EMOTION RECOGNITION USING RESNET-18 MODEL. International Journal of Advance and Innovative Research, Volume 10(Issue 4 (I) October - December 2023), 94–96.

- [9] Dong, J., Zhang, Y., & Fan, L. (2023). A Multi-View Face Expression Recognition Method Based on DenseNet and GAN. *Electronics*, 12(11), 2527.
- [10] Haposan Vincentius Manalu, Achmad Pratama Rifai, Detection of human emotions through facial expressions using hybrid convolutional neural network-recurrent neural network algorithm, *Intelligent Systems with Applications*, Volume 21, 2024, 200339, ISSN 2667-3053.
- [11] Hung, Bui & Ti  n, L   Minh. (2021). Facial Expression Recognition with CNN-LSTM. 10.1007/978-981-15-7527-3_52.
- [12] Wang, Yan & Yan, Shaoqi & Liu, Yang & Song, Wei & Liu, Jing & Chang, Yang & Mai, Xinji & Hu, Xiping & Zhang, Wenqiang & Gan, Zhongxue. (2024). A Survey on Facial Expression Recognition of Static and Dynamic Emotions. 10.48550/arXiv.2408.15777.
- [13] Chen D., Wen, G., Li, H., Yang, P., Chen, C., & Wang, B. (2024). Multi-geometry embedded transformer for facial expression recognition in videos. *Expert Systems with Applications*, 249, 123635
- [14] Guo, D., Xu, F. STAR-Former: spatio-temporal adaptive and region-aware transformer for dynamic facial expression recognition. *J. King Saud Univ. Comput. Inf. Sci.* 38, 111 (2026)
- [15] Alexei Baevski, Henry Zhou, Abdelrahman Mohamed, and Michael Auli. 2020. Wav2vec 2.0: a framework for self-supervised learning of speech representations. In *Proceedings of the 34th International Conference on Neural Information Processing Systems (NIPS '20)*. Curran Associates Inc., Red Hook, NY, USA, Article 1044, 12449–12460
- [16] W. . Hsu, B. Bolte, Y. -H. H. Tsai, K. Lakhotia, R. Salakhutdinov and A. Mohamed, "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units," in *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 29, pp. 3451-3460, 2021
- [17] Chang, Heng-Jui & Yang, Shu-Wen & Lee, Hung-yi. (2021). DistilHuBERT: Speech Representation Learning by Layer-wise Distillation of Hidden-unit BERT.
- [18] Wu , Y.; Mi, Q.; Gao, T. A Comprehensive Review of Multimodal Emotion Recognition: Techniques, Challenges, and Future Directions. *Biomimetics* 2025, 10, 418
- [19] Sebastian, Jilt & Pierucci, Piero. (2019). Fusion Techniques for Utterance-Level Emotion Recognition Combining Speech and Transcripts. 51-55. 10.21437/Interspeech.2019-3201.
- [20] Chhavi Dixit, Shashank Mouli Satapathy, Deep CNN with late fusion for real time multimodal emotion recognition, *Expert Systems with Applications*, Volume 240, 2024, 122579, ISSN 0957-4174
- [21] Dhanith, P. & Venkatraman, Shravan & Sharma, Vigya & Malarvannan, Santhosh. (2024). Multimodal Emotion Recognition using Audio-Video Transformer Fusion with Cross Attention. 10.48550/arXiv.2407.18552.

- [22] Viola, P., Jones, M.J. Robust Real-Time Face Detection. *International Journal of Computer Vision* 57, 137–154 (2004)
- [23] Kay, Will & Carreira, J. & Simonyan, Karen & Zhang, Brian & Hillier, Chloe & Vijayanarasimhan, Sudheendra & Viola, Fabio & Green, Tim & Back, Trevor & Natsev, Paul & Suleyman, Mustafa & Zisserman, Andrew. (2017). The Kinetics Human Action Video Dataset. 10.48550/arXiv.1705.06950.
- [24] Kunešová, Marie & Zajíc, Zbyněk & Šmídl, Luboš & Karafiát, Martin. (2024). Comparison of wav2vec 2.0 models on three speech processing tasks. *International Journal of Speech Technology*. 27. 847-859. 10.1007/s10772-024-10140-6.
- [25] Zhang , Binbin & Lv, Hang & Guo, Pengcheng & Shao, Qijie & Yang, Chao & Xie, Lei & Xu, Xin & Bu, Hui & Chen, Xiaoyu & Zeng, Chenchen & Wu, Di & Peng, Zhendong. (2022). WENETSPEECH: A 10000+ Hours Multi-Domain Mandarin Corpus for Speech Recognition. 6182-6186. 10.1109/ICASSP43922.2022.9746682.
- [26] Arnab, Anurag & Dehghani, Mostafa & Heigold, Georg & Sun, Chen & Lucic, Mario & Schmid, Cordelia. (2021). ViViT: A Video Vision Transformer. 10.48550/arXiv.2103.15691.